

RAPPORT CONSOLIDÉ ILLUSTRÉ — SKILL GEN-
PLAN V3.17.0

RAPPORT CONSOLIDÉ GEN-PLAN

Regroupement des trois rapports de test en un document unique : T1 — mobilisation des 8 disciplines en mode parallèle ; T2 — pipeline de planification E1-E15 instrumenté ; T3 — réaction à la surcharge réelle des ressources sous G-RES. Chaque partie conserve ses grafjets, ses tableaux de mesures et son verdict ; une synthèse comparative conclut l'ensemble.

Session B13-r7 · Tasks 50-51 · 2026-09-27

Couverture : sommaire + 3 parties + synthèse comparative · Palette : identité Claude/Godot

ÉCOSYSTÈME KNOWLEDGE — USAGE INTERNE

Sommaire

Avant-propos — objet et mode de lecture	1
PARTIE I — Test T1 · Mobilisation des 8 disciplines en parallèle	1
1. Objet et périmètre du test	2
2. Méthodologie et architecture du harnais	3
3. Déroulement du test	5
4. Performances mesurées	6
5. Comportement observé	7
6. Verdict et preuves	8
7. Limites et recommandations	9
PARTIE II — Test T2 · Pipeline de planification E1-E15	9
1. Objet et périmètre du test	9
2. Méthodologie et architecture du harnais	10
3. Déroulement du test	13
4. Performances mesurées	14
5. Comportement observé	15
6. Verdict et preuves	16
7. Limites et recommandations	17
PARTIE III — Test T3 · Réaction à la surcharge des ressources	17
1. Objet et périmètre du test	17
2. Méthodologie et architecture du harnais	18
3. Déroulement du test	21
4. Performances mesurées	22
5. Comportement observé	23
6. Verdict et preuves	24
7. Limites et recommandations	25
PARTIE IV — Synthèse comparative	25
8. Vue d'ensemble des trois tests	25
9. Lecture transversale	26
10. Limites communes et perspectives	27

Avant-propos — objet et mode de lecture

Ce document consolide en un volume unique les trois rapports de test produits en Task 50 à la demande du propriétaire de l'écosystème (directive trace 1a0e074494548cd9) : T1 — la mobilisation des huit disciplines d'ingénierie en mode parallèle, T2 — le parcours instrumenté de la chaîne de planification E1-E15, et T3 — la réaction à une surcharge réelle des ressources sous la garde G-RES. La consolidation répond à la directive de regroupement (trace 1a0e0b10c2921599) : une couverture commune, un sommaire unique, les trois parties reproduites avec leurs grafjets, leurs tableaux de mesures et leurs verdicts, puis une synthèse comparative qui met les trois campagnes en perspective. Chaque partie reste autonome et conserve la numérotation interne de son rapport d'origine, de sorte qu'un lecteur puisse la citer isolément sans ambiguïté.

Les trois tests partagent la même méthode d'inspection : un harnais mécanique en bibliothèque standard, persisté sous scripts/ avant exécution (R9), des missions déterministes contrôlées par empreintes sha16, la garde transversale G-RES aux ouverture et clôture, un timer d'abandon armé à 240 secondes et la preuve d'idempotence $\times 2$ (D017). Les verdicts portent donc sur la structure — plan généré conforme, missions PASS, signatures stables entre passes — et non sur les durées, qui varient légitimement d'une machine à l'autre. La mise en page chromatique du volume reprend l'identité crème / terracotta / encre de l'écosystème, le bleu Godot étant réservé en accent secondaire aux séries graphiques marquant le parallélisme.

Le mode de lecture recommandé suit l'ordre des parties : T1 établit la propriété de base (un plan parallèle produit les mêmes résultats qu'un plan série, plus vite), T2 vérifie l'enchaînement complet de la planification avec ses trois hooks structurels, T3 éprouve la robustesse face à la pression réelle des ressources. La quatrième partie rapproche ensuite les trois campagnes : tableau comparatif des paramètres et verdicts, lecture transversale de ce que l'ensemble démontre, puis limites communes et perspectives de tests complémentaires.

PARTIE I — Test T1 · Mobilisation des 8 disciplines en parallèle

Le test T1 vérifie la propriété fondatrice du mode d'exécution PARALLELE : les huit disciplines d'ingénierie de l'écosystème peuvent être décrites dans un plan commun puis exécutées sur huit processus simultanés, sans modifier le moindre verdict. La campagne mesure une accélération du temps de mur, prouve l'idempotence $\times 2$ et tient le budget avec plus de 97 % de marge. Les sept chapitres qui suivent détaillent les paramètres, la méthodologie, le déroulement, les mesures, le comportement, le verdict et les limites.

1. Objet et périmètre du test

Cette première partie regroupe le rapport du test **T1** du skill gen-plan v3.17.0, exécuté le 2026-09-27 dans la session B13-r7 (Task 50) à la demande du propriétaire de l'écosystème (directive trace 1a0e074494548cd9). L'objectif est de vérifier que les **huit disciplines** d'ingénierie à la disposition de gen-plan — spec-driven-development, memory-engineering, fleet-engineering, context-engineering, graph-engineering, harness-engineering, loop-engineering et prompt-engineering — peuvent être mobilisées ensemble, décrites dans un plan d'actions généré selon la structure E1-E8, puis exécutées **en parallèle** dans la limite stricte de quatre minutes. Le test mesure en particulier le gain du mode PARALLELE (Graph Diamond) par rapport à une baseline SERIE, et la stabilité des verdicts entre deux passes consécutives (idempotence D017).

1.1 Paramètres du test

Le test s'exécute intégralement en local, sans appel réseau ni modèle de langage : seules des opérations déterministes (hachage, tri, graphes, fichiers JSON) constituent la charge utile. Un timer de sécurité de 240 secondes est armé avant la première étape ; s'il expire, le plan est abandonné proprement avec un checkpoint partiel (L002), ce qui garantit qu'aucune exécution ne peut dépasser le plafond imposé par la directive. La garde transversale G-RES encadre le test : une collecte monitor.py est réalisée à l'ouverture et à la clôture, et le verdict d'ouverture était **OK** (mode PARALLELE).

Paramètre	Valeur
Directive	trace 1a0e074494548cd9 (Task 50)
Skill testé	gen-plan v3.17.0 (écosystème Knowledge local)
Budget	240 s maximum — timer d'abandon armé
Mode d'exécution	PARALLELE (Graph Diamond E9-E14)
Verdict global	ALL PASS
Temps de mur mesuré	6,09 s (2,5 % du budget)

Tableau T1 1 — Paramètres et résultat de tête du test T1

2. Méthodologie et architecture du harnais

Le harnais est matérialisé par quatre scripts Python persistés sous **scripts/** avant exécution (règle R9), en-têtes PROVENANCE (convention N27/L006) et limités à la bibliothèque standard (norme N3) : un module de missions, un module de moteurs d'exécution et deux à trois lanceurs par test. Chaque discipline est incarnée par une **mission** qui produit un artefact déterministe contrôlé par une empreinte sha16 : la vérification porte sur la structure (verdict PASS/FAIL et empreinte), jamais sur les durées, qui varient légitimement d'une exécution à l'autre. C'est cette distinction qui rend l'idempotence ×2 (D017) significative : les signatures structurelles doivent être identiques entre les deux passes, tandis que les chronométrages restent libres.

2.1 Missions des disciplines

Discipline	Technique testée	Preuve mécanique	Verdict
spec-driven-development	Contrat de spécification AVANT implémentation	conformité AC-1 vérifiée (tri+dédoublonnage déterministe)	PASS
memory-engineering	État long → compaction → re-trouvabilité	journal de 60 entrées compacté en 6, re-lecture fidèle	PASS
fleet-engineering	Fan-out de sous-tâches + agrégation	manifeste de 6 sous-tâches, signatures sha16	PASS
context-engineering	Curation sous budget d'attention	sélection sous 120 jetons, priorités respectées	PASS
graph-engineering	Graphe versionné bidirectionnel + BFS	8 nœuds / 12 arêtes réciproques, distances n0 calculées	PASS
harness-engineering	Garde-fous (pré-conditions)	violation attrapée, cas nominal 10 → 55	PASS
loop-engineering	Boucle exécuter → noter → corriger	grade v1 FAIL détecté, correction, grade v2 PASS	PASS
prompt-engineering	Scoring structurel d'un artefact prompt	10/10 checks structurels (seuil 9)	PASS

Tableau T1 2 — Les 8 disciplines mobilisées et leur preuve mécanique (T1)

2.2 Grafcet du test

Le grafcet ci-dessous décrit le fonctionnement séquentiel du test : chaque carte de phase regroupe des étapes exécutées dans son contexte, et les flèches matérialisent les transitions entre phases. La représentation est volontairement simplifiée (vue d'ensemble) ; les détails opérationnels figurent dans les tableaux des chapitres 3 et 4, conformément à la stratégie « table de détail + diagramme simplifié ».

Grafcet T1 — Mobilisation des 8 disciplines en mode parallèle

gen-plan v3.17.0 · budget 240 s · timer armé · D017 x2




Figure T1 1a — Grafcet du test T1, phases 1 à 3

Grafcet T1 — Mobilisation des 8 disciplines en mode parallèle (suite)

gen-plan v3.17.0 · budget 240 s · timer armé · D017 ×2 — suite




Figure T1 1b — Grafcet du test T1, phases 4 et 5 (suite)

3. Déroulement du test

Le déroulement suit strictement le grafcet du chapitre 2. Après la collecte G-RES d'ouverture (verdict OK, mode PARALLELE), le harnais génère le plan d'actions E1-E8 décrivant deux groupes d'exécution (baseline SERIE et vague PARALLELE) puis l'arbitre interne contrôle mécaniquement ses sections. La passe 1 exécute d'abord les huit missions séquentiellement, puis les huit missions sur huit processus dédiés (ProcessPoolExecutor) ; la passe 2 rejoue l'intégralité du cycle pour la preuve d'idempotence. Aucun événement anormal n'a interrompu le déroulement et le timer n'a jamais été approché : le test complet consomme moins de 3 % du budget imparti, les deux passes incluses.

3.1 Chronologie instrumentée

Étape	Résultat	Mesure
G-RES ouverture	OK / PARALLELE	verdict monitor.py
Plan E1-E8 généré + contrôlé	6/6 checks	plan-T1.md
Baseline SERIE (8 missions)	8/8 PASS	1,79 s
Vague PARALLELE (8 processus)	8/8 PASS	1,22 s
Passe 2 (idempotence)	signatures identiques	D017
G-RES clôture	OK	verdict monitor.py
Timer 240 s	non déclenché	6,09 s au total

Tableau T1 6 — Chronologie du test T1 (passe 1 pour les mesures)

4. Performances mesurées

1,79 s Baseline SERIE — 8 disciplines	1,22 s Vague PARALLELE — 8 processus	× 1,47 Accélération mesurée (mur)	2,5 % Budget 240 s consommé
---	--	---	---------------------------------------

Le résultat central du test est une **accélération ×1,47** : le temps de mur chute de 1,79 s en série à 1,22 s en parallèle pour un travail CPU identique (environ 2,8 Go de hachage cumulé). Ce gain, réel mais modeste au regard des huit processus mobilisés, s'explique par le profil du bac à sable : le nombre de vCPU disponibles est limité, et le hachage saturant, les huit processus se partagent les cœurs physiques. La mesure valide néanmoins la chaîne complète — fan-out, exécution concurrente, jonction — et montre que la surcharge d'orchestration (démarrage du pool, sérialisation) reste marginale. Sur une machine au profil NORMAL plus large, l'accélération se rapprocherait du rapport entre le nombre de missions et de cœurs, jusqu'au plafond imposé par la charge indivisible de préparation.

4.1 Détail par discipline

Le tableau ci-dessous ventile les durées internes de chaque mission. En mode PARALLELE, la durée interne d'une mission inclut la contention CPU avec ses consœurs : sur ce bac à sable limité en vCPU, chaque processus progresse plus lentement mais tous progressent simultanément, d'où un temps de mur total inférieur malgré des durées internes plus élevées. C'est le comportement attendu d'une exécution réellement parallèle sur une machine contrainte.

Discipline	Durée SERIE	Durée PARALLELE (contention incluse)	Charge CPU	Verdict
spec-driven-development	0,22 s	0,88 s	360 Mo	PASS
memory-engineering	0,24 s	1,10 s	390 Mo	PASS
fleet-engineering	0,20 s	1,09 s	330 Mo	PASS
context-engineering	0,23 s	1,18 s	375 Mo	PASS
graph-engineering	0,21 s	1,13 s	345 Mo	PASS
harness-engineering	0,22 s	1,16 s	360 Mo	PASS
loop-engineering	0,23 s	1,15 s	375 Mo	PASS
prompt-engineering	0,24 s	1,15 s	390 Mo	PASS

Tableau T1 3 — Durées internes par discipline (T1, passe 1)

4.2 Lecture visuelle de l'accélération




Figure T1 2 — Temps de mur total : baseline SERIE contre vague PARALLELE (passe 1)

5. Comportement observé

Le comportement du plan d'actions généré est évalué sur quatre axes : la conformité structurelle du plan produit (sections E1/E7/E8 et groupes parallèles), la santé des missions (verdicts discipline par discipline), l'idempotence des verdicts entre deux exécutions (D017) et la tenue du budget temporel face au timer. Les constats ci-dessous sont tirés des rapports JSON mécaniques produits par le harnais, sans intervention manuelle.

5.1 Contrôles et verdicts

Contrôle	Résultat observé	Statut
Structure du plan généré	sections E1/E7/E8 présentes, 2 groupes, budget affiché — 6/6 checks	PASS
Verdicts des 8 disciplines	16 exécutions (2 modes × 2 passes), toutes PASS	PASS
Idempotence ×2 (D017)	signatures (discipline, verdict, sha16) identiques entre passes 1 et 2	PASS
G-RES	ouverture OK, clôture OK — aucune pression	PASS
Budget / timer	6,09 s consommées sur 240 s — timer jamais déclenché	PASS

Tableau T1 4 — Contrôles de comportement du test T1

6. Verdict et preuves

Le test T1 est **réussi : verdict global ALL PASS**, obtenu à l'identique sur deux exécutions complètes du script (et deux passes internes par exécution). Le plan d'actions généré par le harnais décrit fidèlement la mécanique gen-plan — analyse de la demande, groupes d'exécution, validation — et l'exécution parallèle produit des résultats structurellement identiques à la baseline série, ce qui est la propriété essentielle attendue d'une parallélisation sûre : le parallélisme change le temps, jamais le résultat. Les empreintes sha16 des huit artefacts de missions servent de preuve de reproductibilité et sont consignées dans le rapport JSON du test.

6.1 Artefacts produits par le test

Artefact	Rôle
results/T1.json	rapport mécanique complet : 2 passes, verdicts, durées, G-RES
plans/plan-T1.md	plan d'actions E1-E8 généré (groupes SERIE + PARALLELE)
artefacts//	8 jeux d'artefacts de missions (spécifications, graphes, journaux...)
grafcets/grafcet-T1-p1/p2.png	grafcets illustrés intégrés au présent rapport

Tableau T1 5 — Artefacts du test T1 (tmp/t50-test-genplan/)

7. Limites et recommandations

Première limite : la puissance du bac à sable. Avec un nombre de vCPU restreint, l'accélération parallèle plafonne à $\times 1,47$ alors que la méthode — fan-out sur huit processus — en supporterait davantage sur du matériel plus large. La mesure n'en reste pas moins fidèle : elle caractérise le comportement du plan sur l'environnement réel d'exécution de l'écosystème, ce qui est précisément l'objet d'un test.

Deuxième limite : la nature mécanique des missions. Chaque discipline est incarnée par une opération déterministe de coût contrôlé, non par un cas d'usage complet métier ; les verdicts portent donc sur la mécanique de mobilisation (découpage, parallélisation, consolidation), pas sur la qualité sémantique des productions d'une discipline dans un vrai projet de planification.

Recommandations : conserver ce harnais comme arbitre de non-régression du pipeline parallèle (rejouable en moins de dix secondes), et créer un test T4 à charge CPU soutenue pour mesurer l'accélération sur plusieurs minutes et affiner la grille #token des plans parallèles.

PARTIE II — Test T2 · Pipeline de planification E1-E15

Le test T2 parcourt la chaîne de planification complète du skill, de l'answer key E1 à la leçon d'observation E15, en exerçant les trois hooks officiellement prescrits. Le Graph Diamond E9-E14 exécute deux vagues parallèles de quatre missions et consolide huit verdicts à la jonction. Les chapitres reproduits ci-dessous montrent que chaque étape produit son artefact mesuré et que le budget reste anecdotique.

1. Objet et périmètre du test

Cette deuxième partie présente le test **T2**, qui parcourt la **chaîne de planification complète** du skill gen-plan — les quinze étapes E1 à E15 — dans un harnais mécanique exécuté le 2026-09-27 (session B13-r7, Task 50, directive trace 1a0e074494548cd9). Là où T1 isole la mobilisation des disciplines, T2 vérifie l'enchaînement : chaque étape produit un artefact mesuré (answer key, inventaire, grille de budgets, graphe de sélection, plan E1-E8, verdicts d'arbitre, leçon d'observation) et les trois hooks officiellement prescrits — answer key en E1, arbitre en E8, knowledge-observer en E15 — sont exercés. Le cœur du test reste l'exécution **parallèle en Graph Diamond** (E9-E14) : deux vagues de quatre missions de disciplines reliées par une jonction, conformément au motif d'orchestration du skill.

1.1 Paramètres du test

Le test s'exécute intégralement en local, sans appel réseau ni modèle de langage : seules des opérations déterministes (hachage, tri, graphes, fichiers JSON) constituent la charge utile. Un timer de sécurité de 240 secondes est armé avant la première étape ; s'il expire, le plan est abandonné proprement avec un checkpoint partiel (L002), ce qui garantit qu'aucune exécution ne peut dépasser le plafond imposé par la directive. La garde transversale G-RES encadre le test : une collecte monitor.py est réalisée à l'ouverture et à la clôture, et le verdict d'ouverture était **OK** (mode SERIE).

Paramètre	Valeur
Directive	trace 1a0e074494548cd9 (Task 50)
Skill testé	gen-plan v3.17.0 (écosystème Knowledge local)
Budget	240 s maximum — timer d'abandon armé
Mode d'exécution	PARALLELE (Graph Diamond E9-E14)
Verdict global	ALL PASS
Temps de mur mesuré	1,30 s (0,5 % du budget)

Tableau T2 1 — Paramètres et résultat de tête du test T2

2. Méthodologie et architecture du harnais

Le harnais est matérialisé par quatre scripts Python persistés sous **scripts/** avant exécution (règle R9), en-têtes PROVENANCE (convention N27/L006) et limités à la bibliothèque standard (norme N3) : un module de missions, un module de moteurs d'exécution et deux à trois lanceurs par test. Chaque discipline est incarnée par une **mission** qui produit un artefact déterministe contrôlé par une empreinte sha16 : la vérification porte sur la structure (verdict PASS/FAIL et empreinte), jamais sur les durées, qui varient légitimement d'une exécution à l'autre. C'est cette distinction qui rend l'idempotence ×2 (D017) significative : les signatures structurelles doivent être identiques entre les deux passes, tandis que les chronométrages restent libres.

2.1 Missions des disciplines

Étape gen-plan	Contenu instrumenté dans le harnais	Artefact
E1 — answer key	5 décisions vérifiables enregistrées (hook officiel)	T2-answer-key.json
E2 — inventaire	comptage des skills locaux et des entrées du registre KB	mesures JSON
E3 — classification	règle Types 1-4 → Type 4 (traitement local)	mesures JSON
E4 — budgets	grille #token par phase, total 10 000	mesures JSON
E5 — sélection	parsing des dépendances du frontmatter gen-plan	mesures JSON
E6 — profilage	collecte monitor.py réelle (G-RES)	state.json
E7 — génération	plan markdown E1-E8 à 3 groupes d'exécution	plan-T2.md
E8 — validation	arbitre du plan ×2 passages identiques (hook)	verdicts
E9-E14 — Graph Diamond	2 vagues PARALLELE de 4 missions + jonction	8 verdicts
E15 — observation	leçon knowledge-observer idempotente (hook)	T2-lecon.json

Tableau T2 2 — Les 8 disciplines mobilisées et leur preuve mécanique (T2)

2.2 Grafcet du test

Le grafcet ci-dessous décrit le fonctionnement séquentiel du test : chaque carte de phase regroupe des étapes exécutées dans son contexte, et les flèches matérialisent les transitions entre phases. La représentation est volontairement simplifiée (vue d'ensemble) ; les détails opérationnels figurent dans les tableaux des chapitres 3 et 4, conformément à la stratégie « table de détail + diagramme simplifié ».

Grafcet T2 — Pipeline gen-plan E1 → E15 instrumenté

hooks E1/E8/E15 · Graph Diamond E9-E14 · budget 240 s



Figure T2 1a — Grafcet du test T2, phases 1 à 3 (E1-E8)

Grafcet T2 — Pipeline gen-plan E1 → E15 instrumenté (suite)

hooks E1/E8/E15 · Graph Diamond E9-E14 · budget 240 s — suite



Figure T2 1b — Grafcet du test T2, phases 4 à 6 (E9-E15, suite)

3. Déroulement du test

L'exécution déroule les dix étapes instrumentées dans l'ordre imposé par le skill : planification (E1-E4), sélection et profilage (E5-E6), génération et validation (E7-E8), puis le diamant d'exécution (E9-E14) et l'observation (E15). Les étapes de planification se jouent en quelques millisecondes chacune, ce qui est cohérent avec leur nature (comptages et écritures de petits artefacts) ; l'essentiel du temps de mur — environ 1,2 seconde sur 1,3 — est consommé par le Graph Diamond, c'est-à-dire par les huit missions réelles de disciplines. Le script a été exécuté deux fois intégralement : les verdicts de chaque étape sont identiques d'un run à l'autre et la leçon E15 a incrémenté son compteur d'occurrences au lieu de dupliquer une entrée, conformément à l'idempotence attendue.

3.1 Chronologie instrumentée

Étape	Verdict	Durée
E1_answer_key	PASS	0 ms
E2_inventaire	PASS	1 ms
E3_classification	PASS	0 ms
E4_budgets	PASS	0 ms
E5_selection	PASS	0 ms
E6_profilage	PASS	27 ms
E7_generation	PASS	0 ms
E8_validation_x2	PASS	0 ms
E9-E14_graph_diamond	PASS	1,24 s
E15_observation	PASS	0 ms

Tableau T2 6 — Chronologie instrumentée des étapes E1-E15 (run 1)

4. Performances mesurées

10 / 15 étapes gen-plan instrumentées (E1-E15)	8 / 8 missions PASS dans le Graph Diamond	1,30 s temps de mur total	0,5 % budget 240 s consommé
---	--	-------------------------------------	---------------------------------------

La répartition des temps confirme la hiérarchie attendue : les étapes de planification sont quasi gratuites (millisecondes) tandis que le **Graph Diamond consomme 1,24 s** pour ses deux vagues parallèles (vague 1 : 0,60 s ; vague 2 : 0,64 s) et la jonction. Les huit missions y sont exécutées sur des processus séparés — quatre par vague — et toutes renvoient PASS avec leurs empreintes sha16, la jonction E14 consolidant 8/8 verdicts. Le budget de 240 secondes est consommé à hauteur de 0,5 % seulement : le plafond de quatre minutes est largement tenu, y compris avec la marge d'orchestration (démarrage des pools, collectes monitor).

4.2 Lecture visuelle de la chronologie




Figure T2 2 — Durée de chaque étape E1-E15 ; le Graph Diamond domine le temps de mur

5. Comportement observé

Le comportement du plan d'actions généré est évalué sur quatre axes : la conformité structurelle du plan produit (sections E1/E7/E8 et groupes parallèles), la santé des missions (verdicts discipline par discipline), l'idempotence des verdicts entre deux exécutions (D017) et la tenue du budget temporel face au timer. Les constats ci-dessous sont tirés des rapports JSON mécaniques produits par le harnais, sans intervention manuelle.

5.1 Contrôles et verdicts

Contrôle	Résultat observé	Statut
Hooks prescrits	E1 answer key, E8 arbitre ×2 identique, E15 leçon idempotente — tous levés	PASS
Ordre des étapes	E1 → E15 strictement séquentiel, aucune inversion	PASS
Graph Diamond	vagues PARALLELE 4+4, jonction 8/8 PASS, consolidation cohérente	PASS
Idempotence externe ×2 (D017)	deux exécutions complètes : verdicts identiques étape par étape	PASS
G-RES	ouverture OK, clôture OK	PASS
Budget / timer	1,30 s sur 240 s — timer non déclenché	PASS

Tableau T2 4 — Contrôles de comportement du test T2

6. Verdict et preuves

Le test T2 est **réussi : verdict global ALL PASS** sur deux exécutions. Il démontre que la chaîne de planification du skill peut être parcourue de bout en bout par un exécutant mécanique, que les trois hooks structurels se lèvent aux emplacements prescrits et que le motif Graph Diamond consolide correctement deux vagues parallèles. Les artefacts intermédiaires — answer key, plan, leçon — sont retrouvés en place avec les contenus attendus, et la leçon d'observation E15 respecte la règle d'idempotence (occurrences incrémentées, pas de doublon), préfigurant le comportement du journal knowledge-observer en production.

6.1 Artefacts produits par le test

Artefact	Rôle
results/T2.json	rapport mécanique : 10 étapes, verdicts, durées, missions
plans/plan-T2.md	plan E1-E8 à 3 groupes (2 vagues PARALLELE + jonction)
T2-answer-key.json	answer key E1 : 5 décisions vérifiables
T2-lecon.json	leçon E15 (knowledge-observer, occurrences idempotentes)
artefacts//	8 jeux d'artefacts des missions du diamant

Tableau T2 5 — Artefacts du test T2 (tmp/t50-test-genplan/)

7. Limites et recommandations

Première limite : la fidélité du substitut. Les étapes E1-E15 sont instrumentées par des opérations mécaniques équivalentes (comptages, parsing, écritures) plutôt que par le raisonnement d'un agent ; le test valide l'enchaînement, les hooks et les artefacts, non la qualité de jugement de chaque étape telle qu'un planificateur humain ou LLM l'exercerait.

Deuxième limite : l'échelle du diamant. Deux vagues de quatre missions suffisent à éprouver le motif de parallélisation mais ne représentent pas un plan de production à plusieurs dizaines de tâches ; la jonction reste simple (un niveau), sans dépendances croisées entre vagues.

Recommandations : étendre le harnais à un diamant à trois niveaux avec dépendances croisées pour éprouver la consolidation en présence de chemins concurrents, et brancher l'answer key du harnais sur le registre answer-key de la session pour une traçabilité E1 pleinement native.

PARTIE III — Test T3 · Réaction à la surcharge des ressources

Le test T3 soumet le pipeline à une occupation mémoire réelle jusqu'au verdict PRESSION du monitor G-RES, puis vérifie la chaîne de défense complète : bascule R-RES2, adaptation R-RES3, checkpoint L002 et rétablissement. Les latences mesurées — quelques secondes en détection comme en rétablissement — illustrent une dégradation maîtrisée. Le timer d'abandon reste armé pendant toute la campagne sans jamais devoir trancher.

1. Objet et périmètre du test

Cette troisième partie présente le test **T3**, dédié à la **réaction du skill gen-plan face à une trop forte augmentation de la consommation des ressources**, toujours sous le budget de quatre minutes et son timer d'abandon (session B13-r7, Task 50, directive trace 1a0e074494548cd9). À la différence de T1 et T2, la charge ici n'est pas une simple charge de travail : un processus injecteur distinct alloue de la mémoire **réellement** — par blocs de 128 Mo toutes les 0,25 s, pages engagées — jusqu'à faire basculer le verdict du monitor G-RES de OK à PRESSION (mémoire disponible ≤ 1536 Mo). Le test vérifie alors la chaîne de réaction prescrite par le plan de l'écosystème : détection, bascule R-RES2 vers le mode SERIE, adaptation R-RES3 (payload réduit), checkpoint L002, puis rétablissement après relâche.

1.1 Paramètres du test

Le test s'exécute intégralement en local, sans appel réseau ni modèle de langage : seules des opérations déterministes (hachage, tri, graphes, fichiers JSON) constituent la charge utile. Un timer de sécurité de 240 secondes est armé avant la première étape ; s'il expire, le plan est abandonné proprement avec un checkpoint partiel (L002), ce qui garantit qu'aucune exécution ne peut dépasser le plafond imposé par la directive. La garde transversale G-RES encadre le test : une collecte monitor.py est réalisée à l'ouverture et à la clôture, et le verdict d'ouverture était **OK** (mode SERIE).

Paramètre	Valeur
Directive	trace 1a0e074494548cd9 (Task 50)
Skill testé	gen-plan v3.17.0 (écosystème Knowledge local)
Budget	240 s maximum — timer d'abandon armé
Mode d'exécution	PARALLELE (Graph Diamond E9-E14)
Verdict global	ALL PASS
Temps de mur mesuré	7,07 s (2,9 % du budget)

Tableau T3 1 — Paramètres et résultat de tête du test T3

2. Méthodologie et architecture du harnais

Le harnais est matérialisé par quatre scripts Python persistés sous **scripts/** avant exécution (règle R9), en-têtes PROVENANCE (convention N27/L006) et limités à la bibliothèque standard (norme N3) : un module de missions, un module de moteurs d'exécution et deux à trois lanceurs par test. Chaque discipline est incarnée par une **mission** qui produit un artefact déterministe contrôlé par une empreinte sha16 : la vérification porte sur la structure (verdict PASS/FAIL et empreinte), jamais sur les durées, qui varient légitimement d'une exécution à l'autre. C'est cette distinction qui rend l'idempotence ×2 (D017) significative : les signatures structurelles doivent être identiques entre les deux passes, tandis que les chronométrages restent libres.

2.1 Missions des disciplines

Mécanisme testé	Mise en œuvre dans le harnais	Référence
Injection de pression réelle	processus séparé, blocs de 128 Mo engagés (RSS), cible $\approx 72\%$ de la mémoire disponible initiale	injecteur_pression ()
Sondage G-RES	monitor.py toutes les 2 s, timeline (t, verdict, mémoire) conservée	R-RES1
Détection PRESSION	premier verdict PRESSION — latence mesurée depuis l'injection	seuils monitor
Bascule R-RES2	vague 2 basculée de PARALLELE vers SERIE dès la détection	G-RES R-RES2
Adaptation R-RES3	payload des missions réduit (scale 0,5) — cascade niveau (b)	G-RES R-RES3
Checkpoint L002	mini-snapshot zip des artefacts + empreinte sha16	leçon L002
Rétablissement	relâche mémoire puis verdict OK confirmé — latence mesurée	R-RES2
Timer de sécurité	abandon à 240 s si le plan ne s'achève pas (checkpoint partiel)	directive

Tableau T3 2 — Les 8 disciplines mobilisées et leur preuve mécanique (T3)

2.2 Grafcet du test

Le grafcet ci-dessous décrit le fonctionnement séquentiel du test : chaque carte de phase regroupe des étapes exécutées dans son contexte, et les flèches matérialisent les transitions entre phases. La représentation est volontairement simplifiée (vue d'ensemble) ; les détails opérationnels figurent dans les tableaux des chapitres 3 et 4, conformément à la stratégie « table de détail + diagramme simplifié ».

Grafcet T3 — Réaction à la surcharge des ressources (G-RES)

pression mémoire RÉELLE · R-RES2/R-RES3 · checkpoint L002 · timer 240 s



Figure T3 1a — Grafcet du test T3, phases 1 à 4 (normal → réaction)

Grafcet T3 — Réaction à la surcharge des ressources (G-RES) (suite)

pression mémoire RÉELLE · R-RES2/R-RES3 · checkpoint L002 · timer 240 s — suite




Figure T3 1b — Grafcet du test T3, phases 5 à 7 (checkpoint → clôture, suite)

3. Déroulement du test


Le test démarre en régime normal : la collecte G-RES d'ouverture renvoie OK avec 3,63 Go disponibles, et la vague 1 de quatre missions s'exécute en PARALLELE sans anomalie. L'injecteur démarre alors : la mémoire disponible chute de manière quasi linéaire, la sonde enregistre la descente, et le verdict **PRESSION** apparaît à la quatrième sonde, soit 4,1 s après le début de l'injection. Immédiatement, le plan bascule en **SERIE** avec un payload réduit (R-RES2/R-RES3) et consigne un checkpoint L002 ; l'injecteur est relâché, la mémoire remonte, et le verdict **OK** est confirmé avant une vague post-rétablissement qui valide l'intégrité du pipeline. Le script a été exécuté deux fois avec des résultats structurellement identiques et des latences quasi identiques (4,09/4,11 s en détection ; 2,06 s de rétablissement), gage de robustesse de la mesure.

3.1 Chronologie instrumentée

Étape	Verdict	Durée / latence
vague1_parallele	PASS	406 ms
detection_pression	PASS	4,11 s
bascule_rres2_serie_scale_0.5	PASS	332 ms
checkpoint_l002	PASS	3 ms
retablissement_ok	PASS	2,06 s
post_retablissement_serie	PASS	121 ms

Tableau T3 6 — Chronologie du test T3 (pression réelle, run 1)

4. Performances mesurées



Trois mesures caractérisent la réaction. **Détection** : 4,1 s entre le début de l'injection et le premier verdict PRESSION — la rampe mémoire (2,1 Go en ~4 s) est détectée dès la sonde qui franchit le seuil de 1,536 Go. **Réaction** : la bascule R-RES2 vers SERIE avec payload réduit s'exécute en 0,33 s et les trois missions de la vague dégradée renvoient toutes PASS — la sécurité ne sacrifie pas la complétude. **Rétablissement** : après relâche, le retour au verdict OK est confirmé en 2,06 s, et la vague post exclut toute dégradation résiduelle. Le temps de mur total reste de 7,07 s, soit 2,9 % du budget : le timer n'a pas eu à trancher, mais il était armé — conformément à la demande — pour garantir qu'un plan bloqué aurait été abandonné avec son checkpoint.

4.2 Chronologie mémoire illustrée




Figure T3 2 — Mémoire disponible pendant le test : rampe, seuil PRESSION, rétablissement

5. Comportement observé

Le comportement du plan d'actions généré est évalué sur quatre axes : la conformité structurelle du plan produit (sections E1/E7/E8 et groupes parallèles), la santé des missions (verdicts discipline par discipline), l'idempotence des verdicts entre deux exécutions (D017) et la tenue du budget temporel face au timer. Les constats ci-dessous sont tirés des rapports JSON mécaniques produits par le harnais, sans intervention manuelle.

5.1 Contrôles et verdicts

Contrôle	Résultat observé	Statut
Détection de la surcharge	PRESSION détectée en 4,1 s (seuil 1,536 Go franchi)	PASS
Bascule R-RES2	vague 2 exécutée en SERIE après détection — 3/3 missions PASS	PASS
Adaptation R-RES3	payload réduit (scale 0,5) effectif sur la vague dégradée	PASS
Checkpoint L002	snapshot zip 3287 octets, sha16 23e7f26886095b87	PASS
Rétablissement	verdict OK confirmé en 2,06 s ; vague post PASS	PASS
Idempotence externe ×2 (D017)	deux exécutions : verdicts identiques, latences stables ($\pm$ 0,02 s)	PASS
Budget / timer	7,07 s sur 240 s — plan achevé, timer jamais déclenché	PASS

Tableau T3 4 — Contrôles de comportement du test T3

6. Verdict et preuves

Le test T3 est **réussi : verdict global ALL PASS** sur deux exécutions, plan achevé dans tous les cas. Il démontre que la chaîne de défense prescrite à gen-plan — surveiller (R-RES1), détecter (seuils du monitor), réagir (bascule R-RES2), s'adapter (cascade R-RES3), protéger l'état (checkpoint L002) puis rétablir — fonctionne de bout en bout face à une surcharge **réelle** et non simulée : la mémoire a été physiquement occupée, le monitor a réellement franchi son seuil, et le plan a réellement changé de mode d'exécution en cours de route. Le timer demandé par le propriétaire était armé pendant toute la durée du test et aurait produit un abandon propre avec checkpoint partiel si le plan n'était pas parvenu à son terme.

6.1 Artefacts produits par le test

Artefact	Rôle
results/T3.json	rapport mécanique : étapes, latences, timeline G-RES complète
plans/plan-T3.md	plan E1-E8 à 4 groupes (dont phase PRESSION et rétablissement)
checkpoint-T3.zip	checkpoint L002 : snapshot zip des artefacts du test
T3-injecteur.json	progression de l'injecteur mémoire (tenu, relâche)
grafcets/c3-t3-chronologie-memoire.png	chronologie mémoire illustrée (Figure T3 2)

Tableau T3 5 — Artefacts du test T3 (tmp/t50-test-genplan/)

7. Limites et recommandations

Première limite : la nature de la pression injectée. Le test occupe de la mémoire vive réelle mais de façon brève et contrôlée (quelques secondes de palier) ; il ne couvre ni une pression disque (quota presque plein), ni une pression prolongée de plusieurs minutes, ni un dépassement vers le niveau CRITIQUE — délibérément, pour ne pas fragiliser l'environnement de l'écosystème.

Deuxième limite : la granularité de la sonde. Avec un sondage toutes les 2 s, la latence de détection mesurée inclut jusqu'à 2 s de discrétisation ; la latence réelle du monitor est donc inférieure ou égale à la valeur rapportée, ce qui rend le verdict du test prudent plutôt qu'optimiste.

Recommandations : compléter par un test T5 de pression CRITIQUE contrôlée (en environnement isolé) pour vérifier la règle PAUSE + checkpoint intégral, et réduire l'intervalle de sondage à 1 s dans les phases à risque pour affiner la latence de détection.

PARTIE IV — Synthèse comparative

Cette quatrième et dernière partie rapproche les trois campagnes : tableau comparatif des paramètres et verdicts, lecture transversale des propriétés démontrées, limites communes et perspectives d'évolution du banc d'essai.

8. Vue d'ensemble des trois tests

Les trois campagnes couvrent trois questions complémentaires posées au skill gen-plan : sait-il mobiliser toutes ses disciplines en parallèle (T1), sait-il dérouler la chaîne complète de planification avec ses hooks (T2), et sait-il réagir quand l'environnement se dégrade (T3) ? Le tableau ci-dessous rapproche les paramètres et résultats de tête des trois tests ; la figure qui suit compare les temps de mur mesurés. Dans les trois cas, le budget de 240 secondes est respecté avec une marge supérieure à 97 %, aucun timer n'a eu à déclencher d'abandon, et le verdict global ALL PASS a été obtenu deux fois consécutivement pour chaque test, conformément à l'idempotence D017.

Dimension	T1 — Disciplines parallèle	T2 — Pipeline E1-E15	T3 — Surcharge ressources
Objet du test	8 disciplines mobilisées, baseline SERIE vs vague PARALLELE	chaîne E1 → E15 instrumentée, hooks E1/E8/E15	pression mémoire réelle, réaction G-RES complète
Charge	2 modes × 8 missions × 2 passes	10 étapes + 8 missions en Graph Diamond (4+4)	injecteur RAM (128 Mo / 0,25 s) + vagues dégradées
Temps de mur	6,09 s	1,30 s	7,07 s
Budget consommé	2,5 %	0,5 %	2,9 %

Dimension	T1 — Disciplines parallèle	T2 — Pipeline E1-E15	T3 — Surcharge ressources
Verdict global	ALL PASS (×2)	ALL PASS (×2)	ALL PASS (×2)
Preuve clé	accélération × 1,47, verdicts identiques au série	jonction 8/8 PASS, leçon E15 idempotente	détection 4,1 s, rétablissement 2,06 s

Tableau IV IV 1 — Comparaison d'ensemble des trois tests consolidés



8.1 Lecture visuelle des temps de mur




Figure IV IV 2 — Temps de mur des trois tests : T2 domine en rapidité, T3 en durée, aucun n'approche du plafond de 240 s

9. Lecture transversale

Prise séparément, chaque campagne valide une propriété ; prises ensemble, elles tracent le profil complet d'un plan exécutable digne de production. T1 démontre d'abord que le parallélisme est **sûr** : la vague PARALLELE produit des verdicts structurellement identiques à la baseline série — le parallélisme change le temps, jamais le résultat — tout en apportant un gain de mur mesuré. T2 démontre ensuite que le parallélisme s'insère dans une **chaîne complète** : les quinze étapes se déroulent dans l'ordre prescrit, les trois hooks officiels se lèvent aux emplacements attendus, et le motif Graph Diamond consolide deux vagues concurrentes sans perte de verdict.

T3 démontre enfin que cette chaîne reste **maîtrisée sous contrainte** : face à une occupation mémoire physique réelle, la garde G-RES détecte la pression en environ quatre secondes, le plan bascule en mode

dégradé série avec payload réduit sans sacrifier une seule mission, l'état est protégé par un checkpoint, et le rétablissement est confirmé en deux secondes après relâche. La conjonction des trois propriétés constitue précisément le contrat d'usage du skill : un plan généré est un contrat exécutable, parallélisable et supervisé, dont le comportement ne dépend pas de la bonne volonté de l'environnement mais de règles mécaniques vérifiées.

Un dernier point commun mérite d'être souligné : la reproductibilité. Les trois harnais ont été exécutés deux fois intégralement, avec des verdicts identiques et des latences stables à quelques centièmes de seconde ; les empreintes sha16 des artefacts servent de preuve de non-altération. Cette discipline d'exécution transforme chaque rapport de test en arbitre de non-régression réutilisable : toute évolution du skill gen-plan peut être rejouée en moins de dix secondes par campagne pour vérifier que les propriétés établies ici tiennent toujours.

10. Limites communes et perspectives

Les limites rappelées dans chaque partie se raccordent en un faisceau cohérent. D'abord, la nature mécanique des missions : les disciplines sont incarnées par des opérations déterministes, de sorte que les verdicts valident la mécanique de mobilisation, d'enchaînement et de réaction — non la qualité sémantique des productions d'un planificateur en situation réelle. Ensuite, l'échelle du banc d'essai : huit missions, deux vagues, une jonction simple, quelques secondes de pression contrôlée — largement suffisant pour éprouver les motifs, mais loin de la diversité d'un plan de production à plusieurs dizaines de tâches et de dépendances croisées. Enfin, le profil matériel du bac à sable, dont les vCPU limités plafonnent l'accélération parallèle mesurée.

Les perspectives dessinées par les trois rapports se combinent en un programme de tests T4-T5 : un test à charge CPU soutenue pendant plusieurs minutes pour mesurer l'accélération au-delà du régime transitoire et affiner la grille de budgets des plans parallèles ; un test de pression CRITIQUE contrôlée, en environnement isolé, pour vérifier la règle PAUSE et le checkpoint intégral ; et l'extension du Graph Diamond à trois niveaux avec dépendances croisées pour éprouver la consolidation en présence de chemins concurrents. À ce stade, la recommandation opérationnelle est simple : conserver les trois harnais comme arbitres de non-régression du pipeline gen-plan, les rejouer à chaque évolution significative du skill, et enrichir progressivement le banc d'essai à mesure que les usages réels de planification révéleront de nouveaux motifs à couvrir.

10.1 Registre des propriétés vérifiées

Le registre ci-dessous condense la matière des trois « Comportements observés » en une grille de re-lecture : chaque ligne est une propriété attendue du pipeline, chaque colonne la campagne qui l'a éprouvée, et chaque case renvoie à une preuve mécanique (verdict, comptage ou latence consignée dans les rapports JSON de Task 50). Il constitue la checklist de référence pour toute re-campagne : un arbitre de non-régression se contente de rejouer les trois harnais puis de vérifier que cette grille reste entièrement au vert.

Propriété vérifiée	Preuve mécanique	T1	T2	T3
Plan généré conforme (sections et groupes)	contrôles E1/E7/E8 du harnais	6/6	conforme	conforme
Missions de disciplines toutes PASS	verdicts + empreintes sha16	16/16	8/8	10/10
Parallélisme sans perte de verdict	jonction et consolidation	× 1,47	8/8	3/3 (dégradé)
Idempotence ×2 (D017)	deux exécutions comparées	signatures	verdicts	latences
Garde G-RES ouverture / clôture	collectes monitor.py	OK / OK	OK / OK	OK · PRESSION · OK
Budget 240 s et timer	temps de mur rapporté	6,09 s	1,30 s	7,07 s

Tableau IV IV 3 — Registre de re-lecture consolidé des propriétés vérifiées

Ce registre éclaire aussi la division du travail entre les trois campagnes : T1 porte la preuve de parallélisme sûr, T2 celle de l'enchaînement complet et des hooks structurels, T3 celle de la défense face aux ressources — aucune case n'est laissée à la seule confiance. En usage courant, la grille se lit en quinze secondes et se rejoue en moins d'une minute sur les trois harnais réunis, ce qui en fait l'outil de vigilance le moins coûteux de l'écosystème pour surveiller gen-plan entre deux évolutions significatives du skill.