

TEST T1 DISCIPLINES EN PARALLÈLE

Mobilisation complète des 8 disciplines d'ingénierie de l'écosystème, exécutées en baseline SERIE puis en vague PARALLELE (Graph Diamond). Mesure de l'accélération, idempotence ×2 des verdicts et budget de 240 secondes contrôlé par un timer de sécurité.

Session B13-r7 · Task 50 · 2026-09-27

Directive trace 1a0e074494548cd9 · Mode d'exécution : PARALLELE

Table des matières

1. Objet et périmètre du test	1
1.1 Paramètres du test	1
2. Méthodologie et architecture du harnais	2
2.1 Missions des disciplines	2
2.2 Grafcet du test	2
3. Déroulement du test	4
3.1 Chronologie instrumentée	4
4. Performances mesurées	5
4.1 Détail par discipline	5
4.2 Lecture visuelle de l'accélération	6
5. Comportement observé	7
5.1 Contrôles et verdicts	7
6. Verdict et preuves	7
6.1 Artefacts produits par le test	7
7. Limites et recommandations	8

1. Objet et périmètre du test

Ce rapport présente le test **T1** du skill gen-plan v3.17.0, exécuté le 2026-09-27 dans la session B13-r7 (Task 50) à la demande du propriétaire de l'écosystème (directive trace 1a0e074494548cd9). L'objectif est de vérifier que les **huit disciplines** d'ingénierie à la disposition de gen-plan — spec-driven-development, memory-engineering, fleet-engineering, context-engineering, graph-engineering, harness-engineering, loop-engineering et prompt-engineering — peuvent être mobilisées ensemble, décrites dans un plan d'actions généré selon la structure E1-E8, puis exécutées **en parallèle** dans la limite stricte de quatre minutes. Le test mesure en particulier le gain du mode PARALLELE (Graph Diamond) par rapport à une baseline SERIE, et la stabilité des verdicts entre deux passes consécutives (idempotence D017).

1.1 Paramètres du test

Le test s'exécute intégralement en local, sans appel réseau ni modèle de langage : seules des opérations déterministes (hachage, tri, graphes, fichiers JSON) constituent la charge utile. Un timer de sécurité de 240 secondes est armé avant la première étape ; s'il expire, le plan est abandonné proprement avec un checkpoint partiel (L002), ce qui garantit qu'aucune exécution ne peut dépasser le plafond imposé par la directive. La garde transversale G-RES encadre le test : une collecte monitor.py est réalisée à l'ouverture et à la clôture, et le verdict d'ouverture était **OK** (mode PARALLELE).

Paramètre	Valeur
Directive	trace 1a0e074494548cd9 (Task 50)
Skill testé	gen-plan v3.17.0 (écosystème Knowledge local)
Budget	240 s maximum — timer d'abandon armé
Mode d'exécution	PARALLELE (Graph Diamond E9-E14)
Verdict global	ALL PASS
Temps de mur mesuré	6,09 s (2,5 % du budget)

Tableau 1 — Paramètres et résultat de tête du test T1

2. Méthodologie et architecture du harnais

Le harnais est matérialisé par quatre scripts Python persistés sous **scripts/** avant exécution (règle R9), en-têtes PROVENANCE (convention N27/L006) et limités à la bibliothèque standard (norme N3) : un module de missions, un module de moteurs d'exécution et deux à trois lanceurs par test. Chaque discipline est incarnée par une **mission** qui produit un artefact déterministe contrôlé par une empreinte sha16 : la vérification porte sur la structure (verdict PASS/FAIL et empreinte), jamais sur les durées, qui varient légitimement d'une exécution à l'autre. C'est cette distinction qui rend l'idempotence $\times 2$ (D017) significative : les signatures structurelles doivent être identiques entre les deux passes, tandis que les chronométrages restent libres.

2.1 Missions des disciplines

Discipline	Technique testée	Preuve mécanique	Verdict
spec-driven-development	Contrat de spécification AVANT implémentation	conformité AC-1 vérifiée (tri+dédoublonnage déterministe)	PASS
memory-engineering	État long → compaction → re-trouvabilité	journal de 60 entrées compacté en 6, re-lecture fidèle	PASS
fleet-engineering	Fan-out de sous-tâches + agrégation	manifeste de 6 sous-tâches, signatures sha16	PASS
context-engineering	Curation sous budget d'attention	sélection sous 120 jetons, priorités respectées	PASS
graph-engineering	Graphe versionné bidirectionnel + BFS	8 nœuds / 12 arêtes réciproques, distances n0 calculées	PASS
harness-engineering	Garde-fous (pré-conditions)	violation attrapée, cas nominal 10 → 55	PASS
loop-engineering	Boucle exécuter → noter → corriger	grade v1 FAIL détecté, correction, grade v2 PASS	PASS
prompt-engineering	Scoring structurel d'un artefact prompt	10/10 checks structurels (seuil 9)	PASS

Tableau 2 — Les 8 disciplines mobilisées et leur preuve mécanique (T1)

2.2 Grafcet du test

Le grafcet ci-dessous décrit le fonctionnement séquentiel du test : chaque carte de phase regroupe des étapes exécutées dans son contexte, et les flèches matérialisent les transitions entre phases. La représentation est volontairement simplifiée (vue d'ensemble) ; les détails opérationnels figurent dans les tableaux des chapitres 3 et 4, conformément à la stratégie « table de détail + diagramme simplifié ».

Grafcet T1 — Mobilisation des 8 disciplines en mode parallèle

gen-plan v3.17.0 · budget 240 s · timer armé · D017 x2



Figure 1a — Grafcet du test T1, phases 1 à 3

Grafcet T1 — Mobilisation des 8 disciplines en mode parallèle (suite)

gen-plan v3.17.0 · budget 240 s · timer armé · D017 ×2 — suite



Figure 1b — Grafcet du test T1, phases 4 et 5 (suite)

3. Déroulement du test

Le déroulement suit strictement le grafcet du chapitre 2. Après la collecte G-RES d'ouverture (verdict OK, mode PARALLELE), le harnais génère le plan d'actions E1-E8 décrivant deux groupes d'exécution (baseline SERIE et vague PARALLELE) puis l'arbitre interne contrôle mécaniquement ses sections. La passe 1 exécute d'abord les huit missions séquentiellement, puis les huit missions sur huit processus dédiés (ThreadPoolExecutor) ; la passe 2 rejoue l'intégralité du cycle pour la preuve d'idempotence. Aucun événement anormal n'a interrompu le déroulement et le timer n'a jamais été approché : le test complet consomme moins de 3 % du budget imparti, les deux passes incluses.

3.1 Chronologie instrumentée

Étape	Résultat	Mesure
G-RES ouverture	OK / PARALLELE	verdict monitor.py
Plan E1-E8 généré + contrôlé	6/6 checks	plan-T1.md
Baseline SERIE (8 missions)	8/8 PASS	1,79 s
Vague PARALLELE (8 processus)	8/8 PASS	1,22 s
Passe 2 (idempotence)	signatures identiques	D017
G-RES clôture	OK	verdict monitor.py
Timer 240 s	non déclenché	6,09 s au total

Tableau — Chronologie du test T1 (passe 1 pour les mesures)

4. Performances mesurées

1,79 s Baseline SERIE — 8 disciplines	1,22 s Vague PARALLELE — 8 processus	× 1,47 Accélération mesurée (mur)	2,5 % Budget 240 s consommé
---	--	---	---------------------------------------

Le résultat central du test est une **accélération ×1,47** : le temps de mur chute de 1,79 s en série à 1,22 s en parallèle pour un travail CPU identique (environ 2,8 Go de hachage cumulé). Ce gain, réel mais modeste au regard des huit processus mobilisés, s'explique par le profil du bac à sable : le nombre de vCPU disponibles est limité, et le hachage saturant, les huit processus se partagent les cœurs physiques. La mesure valide néanmoins la chaîne complète — fan-out, exécution concurrente, jonction — et montre que la surcharge d'orchestration (démarrage du pool, sérialisation) reste marginale. Sur une machine au profil NORMAL plus large, l'accélération se rapprocherait du rapport entre le nombre de missions et de cœurs, jusqu'au plafond imposé par la charge indivisible de préparation.

4.1 Détail par discipline

Le tableau ci-dessous ventile les durées internes de chaque mission. En mode PARALLELE, la durée interne d'une mission inclut la contention CPU avec ses consœurs : sur ce bac à sable limité en vCPU, chaque processus progresse plus lentement mais tous progressent simultanément, d'où un temps de mur total inférieur malgré des durées internes plus élevées. C'est le comportement attendu d'une exécution réellement parallèle sur une machine contrainte.

Discipline	Durée SERIE	Durée PARALLELE (contention incluse)	Charge CPU	Verdict
spec-driven-development	0,22 s	0,88 s	360 Mo	PASS
memory-engineering	0,24 s	1,10 s	390 Mo	PASS
fleet-engineering	0,20 s	1,09 s	330 Mo	PASS
context-engineering	0,23 s	1,18 s	375 Mo	PASS
graph-engineering	0,21 s	1,13 s	345 Mo	PASS
harness-engineering	0,22 s	1,16 s	360 Mo	PASS
loop-engineering	0,23 s	1,15 s	375 Mo	PASS
prompt-engineering	0,24 s	1,15 s	390 Mo	PASS

Tableau — Durées internes par discipline (T1, passe 1)

4.2 Lecture visuelle de l'accélération




Figure 2 — Temps de mur total : baseline SERIE contre vague PARALLELE (passe 1)

5. Comportement observé

Le comportement du plan d'actions généré est évalué sur quatre axes : la conformité structurelle du plan produit (sections E1/E7/E8 et groupes parallèles), la santé des missions (verdicts discipline par discipline), l'idempotence des verdicts entre deux exécutions (D017) et la tenue du budget temporel face au timer. Les constats ci-dessous sont tirés des rapports JSON mécaniques produits par le harnais, sans intervention manuelle.

5.1 Contrôles et verdicts

Contrôle	Résultat observé	Statut
Structure du plan généré	sections E1/E7/E8 présentes, 2 groupes, budget affiché — 6/6 checks	PASS
Verdicts des 8 disciplines	16 exécutions (2 modes × 2 passes), toutes PASS	PASS
Idempotence ×2 (D017)	signatures (discipline, verdict, sha16) identiques entre passes 1 et 2	PASS
G-RES	ouverture OK, clôture OK — aucune pression	PASS
Budget / timer	6,09 s consommées sur 240 s — timer jamais déclenché	PASS

Tableau — Contrôles de comportement du test T1

6. Verdict et preuves

Le test T1 est **réussi : verdict global ALL PASS**, obtenu à l'identique sur deux exécutions complètes du script (et deux passes internes par exécution). Le plan d'actions généré par le harnais décrit fidèlement la mécanique gen-plan — analyse de la demande, groupes d'exécution, validation — et l'exécution parallèle produit des résultats structurellement identiques à la baseline série, ce qui est la propriété essentielle attendue d'une parallélisation sûre : le parallélisme change le temps, jamais le résultat. Les empreintes sha16 des huit artefacts de missions servent de preuve de reproductibilité et sont consignées dans le rapport JSON du test.

6.1 Artefacts produits par le test

Artefact	Rôle
results/T1.json	rapport mécanique complet : 2 passes, verdicts, durées, G-RES
plans/plan-T1.md	plan d'actions E1-E8 généré (groupes SERIE + PARALLELE)
artefacts//	8 jeux d'artefacts de missions (spécifications, graphes, journaux...)
grafcets/grafcet-T1-p1/p2.png	grafcets illustrés intégrés au présent rapport

Tableau — Artefacts du test T1 (tmp/t50-test-genplan/)

7. Limites et recommandations

Première limite : la puissance du bac à sable. Avec un nombre de vCPU restreint, l'accélération parallèle plafonne à $\times 1,47$ alors que la méthode — fan-out sur huit processus — en supporterait davantage sur du matériel plus large. La mesure n'en reste pas moins fidèle : elle caractérise le comportement du plan sur l'environnement réel d'exécution de l'écosystème, ce qui est précisément l'objet d'un test.

Deuxième limite : la nature mécanique des missions. Chaque discipline est incarnée par une opération déterministe de coût contrôlé, non par un cas d'usage complet métier ; les verdicts portent donc sur la mécanique de mobilisation (découpage, parallélisation, consolidation), pas sur la qualité sémantique des productions d'une discipline dans un vrai projet de planification.

Recommandations : conserver ce harnais comme arbitre de non-régression du pipeline parallèle (rejouable en moins de dix secondes), et créer un test T4 à charge CPU soutenue pour mesurer l'accélération sur plusieurs minutes et affiner la grille #token des plans parallèles.