

TEST T2

PIPELINE E1-E15

Chaîne de planification complète E1 → E15 avec hooks instrumentés (answer key E1, arbitre E8, observation E15) et exécution parallèle en Graph Diamond. Chaque étape produit un artefact mesuré : durée, verdict, empreinte. Budget de 240 secondes, timer armé.

Session B13-r7 · Task 50 · 2026-09-27

Directive trace 1a0e074494548cd9 · Mode d'exécution : PARALLELE

Table des matières

1. Objet et périmètre du test	1
1.1 Paramètres du test	1
2. Méthodologie et architecture du harnais	2
2.1 Missions des disciplines	2
2.2 Grafcet du test	2
3. Déroulement du test	4
3.1 Chronologie instrumentée	4
4. Performances mesurées	5
4.2 Lecture visuelle de la chronologie	5
5. Comportement observé	6
5.1 Contrôles et verdicts	6
6. Verdict et preuves	7
6.1 Artefacts produits par le test	7
7. Limites et recommandations	8

1. Objet et périmètre du test

Ce rapport présente le test **T2**, qui parcourt la **chaîne de planification complète** du skill gen-plan — les quinze étapes E1 à E15 — dans un harnais mécanique exécuté le 2026-09-27 (session B13-r7, Task 50, directive trace 1a0e074494548cd9). Là où T1 isole la mobilisation des disciplines, T2 vérifie l'enchaînement : chaque étape produit un artefact mesuré (answer key, inventaire, grille de budgets, graphe de sélection, plan E1-E8, verdicts d'arbitre, leçon d'observation) et les trois hooks officiellement prescrits — answer key en E1, arbitre en E8, knowledge-observer en E15 — sont exercés. Le cœur du test reste l'exécution **parallèle en Graph Diamond** (E9-E14) : deux vagues de quatre missions de disciplines reliées par une jonction, conformément au motif d'orchestration du skill.

1.1 Paramètres du test

Le test s'exécute intégralement en local, sans appel réseau ni modèle de langage : seules des opérations déterministes (hachage, tri, graphes, fichiers JSON) constituent la charge utile. Un timer de sécurité de 240 secondes est armé avant la première étape ; s'il expire, le plan est abandonné proprement avec un checkpoint partiel (L002), ce qui garantit qu'aucune exécution ne peut dépasser le plafond imposé par la directive. La garde transversale G-RES encadre le test : une collecte monitor.py est réalisée à l'ouverture et à la clôture, et le verdict d'ouverture était **OK** (mode SERIE).

Paramètre	Valeur
Directive	trace 1a0e074494548cd9 (Task 50)
Skill testé	gen-plan v3.17.0 (écosystème Knowledge local)
Budget	240 s maximum — timer d'abandon armé
Mode d'exécution	PARALLELE (Graph Diamond E9-E14)
Verdict global	ALL PASS
Temps de mur mesuré	1,30 s (0,5 % du budget)

Tableau 1 — Paramètres et résultat de tête du test T2

2. Méthodologie et architecture du harnais

Le harnais est matérialisé par quatre scripts Python persistés sous **scripts/** avant exécution (règle R9), en-têtes PROVENANCE (convention N27/L006) et limités à la bibliothèque standard (norme N3) : un module de missions, un module de moteurs d'exécution et deux à trois lanceurs par test. Chaque discipline est incarnée par une **mission** qui produit un artefact déterministe contrôlé par une empreinte sha16 : la vérification porte sur la structure (verdict PASS/FAIL et empreinte), jamais sur les durées, qui varient légitimement d'une exécution à l'autre. C'est cette distinction qui rend l'idempotence $\times 2$ (D017) significative : les signatures structurelles doivent être identiques entre les deux passes, tandis que les chronométrages restent libres.

2.1 Missions des disciplines

Étape gen-plan	Contenu instrumenté dans le harnais	Artefact
E1 — answer key	5 décisions vérifiables enregistrées (hook officiel)	T2-answer-key.json
E2 — inventaire	comptage des skills locaux et des entrées du registre KB	mesures JSON
E3 — classification	règle Types 1-4 → Type 4 (traitement local)	mesures JSON
E4 — budgets	grille #token par phase, total 10 000	mesures JSON
E5 — sélection	parsing des dépendances du frontmatter gen-plan	mesures JSON
E6 — profilage	collecte monitor.py réelle (G-RES)	state.json
E7 — génération	plan markdown E1-E8 à 3 groupes d'exécution	plan-T2.md
E8 — validation	arbitre du plan $\times 2$ passages identiques (hook)	verdicts
E9-E14 — Graph Diamond	2 vagues PARALLELE de 4 missions + jonction	8 verdicts
E15 — observation	leçon knowledge-observer idempotente (hook)	T2-lecon.json

Tableau 2 — Les 8 disciplines mobilisées et leur preuve mécanique (T2)

2.2 Grafcet du test

Le grafcet ci-dessous décrit le fonctionnement séquentiel du test : chaque carte de phase regroupe des étapes exécutées dans son contexte, et les flèches matérialisent les transitions entre phases. La représentation est volontairement simplifiée (vue d'ensemble) ; les détails opérationnels figurent dans les tableaux des chapitres 3 et 4, conformément à la stratégie « table de détail + diagramme simplifié ».

Grafcet T2 — Pipeline gen-plan E1 → E15 instrumenté

hooks E1/E8/E15 · Graph Diamond E9-E14 · budget 240 s




Figure 1a — Grafcet du test T2, phases 1 à 3 (E1-E8)

Grafcet T2 — Pipeline gen-plan E1 → E15 instrumenté (suite)

hooks E1/E8/E15 · Graph Diamond E9-E14 · budget 240 s — suite



Figure 1b — Grafcet du test T2, phases 4 à 6 (E9-E15, suite)

3. Déroulement du test

L'exécution déroule les dix étapes instrumentées dans l'ordre imposé par le skill : planification (E1-E4), sélection et profilage (E5-E6), génération et validation (E7-E8), puis le diamant d'exécution (E9-E14) et l'observation (E15). Les étapes de planification se jouent en quelques millisecondes chacune, ce qui est cohérent avec leur nature (comptages et écritures de petits artefacts) ; l'essentiel du temps de mur — environ 1,2 seconde sur 1,3 — est consommé par le Graph Diamond, c'est-à-dire par les huit missions réelles de disciplines. Le script a été exécuté deux fois intégralement : les verdicts de chaque étape sont identiques d'un run à l'autre et la leçon E15 a incrémenté son compteur d'occurrences au lieu de dupliquer une entrée, conformément à l'idempotence attendue.

3.1 Chronologie instrumentée

Étape	Verdict	Durée
E1_answer_key	PASS	0 ms
E2_inventaire	PASS	1 ms
E3_classification	PASS	0 ms
E4_budgets	PASS	0 ms
E5_selection	PASS	0 ms
E6_profilage	PASS	27 ms
E7_generation	PASS	0 ms
E8_validation_x2	PASS	0 ms
E9-E14_graph_diamond	PASS	1,24 s
E15_observation	PASS	0 ms

Tableau — Chronologie instrumentée des étapes E1-E15 (run 1)

4. Performances mesurées

10 / 15 étapes gen-plan instrumentées (E1-E15)	8 / 8 missions PASS dans le Graph Diamond	1,30 s temps de mur total	0,5 % budget 240 s consommé
---	--	-------------------------------------	---------------------------------------

La répartition des temps confirme la hiérarchie attendue : les étapes de planification sont quasi gratuites (millisecondes) tandis que le **Graph Diamond consomme 1,24 s** pour ses deux vagues parallèles (vague 1 : 0,60 s ; vague 2 : 0,64 s) et la jonction. Les huit missions y sont exécutées sur des processus séparés — quatre par vague — et toutes renvoient PASS avec leurs empreintes sha16, la jonction E14 consolidant 8/8 verdicts. Le budget de 240 secondes est consommé à hauteur de 0,5 % seulement : le plafond de quatre minutes est largement tenu, y compris avec la marge d'orchestration (démarrage des pools, collectes monitor).

4.2 Lecture visuelle de la chronologie




Figure 2 — Durée de chaque étape E1-E15 ; le Graph Diamond domine le temps de mur

5. Comportement observé

Le comportement du plan d'actions généré est évalué sur quatre axes : la conformité structurelle du plan produit (sections E1/E7/E8 et groupes parallèles), la santé des missions (verdicts discipline par discipline), l'idempotence des verdicts entre deux exécutions (D017) et la tenue du budget temporel face au timer. Les constats ci-dessous sont tirés des rapports JSON mécaniques produits par le harnais, sans intervention manuelle.

5.1 Contrôles et verdicts

Contrôle	Résultat observé	Statut
Hooks prescrits	E1 answer key, E8 arbitre ×2 identique, E15 leçon idempotente — tous levés	PASS
Ordre des étapes	E1 → E15 strictement séquentiel, aucune inversion	PASS
Graph Diamond	vagues PARALLELE 4+4, jonction 8/8 PASS, consolidation cohérente	PASS
Idempotence externe ×2 (D017)	deux exécutions complètes : verdicts identiques étape par étape	PASS
G-RES	ouverture OK, clôture OK	PASS
Budget / timer	1,30 s sur 240 s — timer non déclenché	PASS

Tableau — Contrôles de comportement du test T2

6. Verdict et preuves

Le test T2 est **réussi : verdict global ALL PASS** sur deux exécutions. Il démontre que la chaîne de planification du skill peut être parcourue de bout en bout par un exécutant mécanique, que les trois hooks structurels se lèvent aux emplacements prescrits et que le motif Graph Diamond consolide correctement deux vagues parallèles. Les artefacts intermédiaires — answer key, plan, leçon — sont retrouvés en place avec les contenus attendus, et la leçon d'observation E15 respecte la règle d'idempotence (occurrences incrémentées, pas de doublon), préfigurant le comportement du journal knowledge-observer en production.

6.1 Artefacts produits par le test

Artefact	Rôle
results/T2.json	rapport mécanique : 10 étapes, verdicts, durées, missions
plans/plan-T2.md	plan E1-E8 à 3 groupes (2 vagues PARALLELE + jonction)
T2-answer-key.json	answer key E1 : 5 décisions vérifiables
T2-lecon.json	leçon E15 (knowledge-observer, occurrences idempotentes)
artefacts//	8 jeux d'artefacts des missions du diamant

Tableau — Artefacts du test T2 (tmp/t50-test-genplan/)

7. Limites et recommandations

Première limite : la fidélité du substitut. Les étapes E1-E15 sont instrumentées par des opérations mécaniques équivalentes (comptages, parsing, écritures) plutôt que par le raisonnement d'un agent ; le test valide l'enchaînement, les hooks et les artefacts, non la qualité de jugement de chaque étape telle qu'un planificateur humain ou LLM l'exercerait.

Deuxième limite : l'échelle du diamant. Deux vagues de quatre missions suffisent à éprouver le motif de parallélisation mais ne représentent pas un plan de production à plusieurs dizaines de tâches ; la jonction reste simple (un niveau), sans dépendances croisées entre vagues.

Recommandations : étendre le harnais à un diamant à trois niveaux avec dépendances croisées pour éprouver la consolidation en présence de chemins concurrents, et brancher l'answer key du harnais sur le registre answer-key de la session pour une traçabilité E1 pleinement native.